Grafos e Redes Sociais

Agrupamento Clássico Adaptado

Prof.

Fernando S. de Aguiar Neto

Sumário

1 K-Means

2 K-Medoids

K-Means

1 K-Means

2 K-Medoids

K-Means

- Um algoritmo clássico é o k-means
  1. Inicializar centróides aleatoriamente
  2. Atribuir amostras ao centroide mais próximo
  3. Atualizar centróides utilizando a média dos elementos pertencentes ao centróide
  4. Repetir 2 e 3 até que nenhuma mudança de pertinência ocorra

Problemas

- Apesar de ser um algoritmo muito simples e eficiente
- Toda a sua formulação espera um espaço euclidiano
- Mas em grafos esse não é o caso
- Primeiramente, não faz sentido pensar em um centróide em grafos, uma vez que esse elemento pode não ser um vértice
- Segundamente, as distâncias entre pares de elementos são não-euclidianas

Alguns pontos

- Podemos utilizar os vértices como pontos centrais dos grupos, o termo usado nesse caso é medóide
- Podemos usar a matriz de adjacências para calcular a distância ou estimar usando shortest path, mas ainda assim, a distância euclidiana não é adequada
- Uma solução que permite outras medidas de distância e usa medóides é o k-Medóides

K-Medoids

1 K-Means

2 K-Medoids

Algoritmo (*Partitioning Around Medoids*, PAM[1])

1. Inicializar k medoids aleatoriamente (do conjunto de dados)
2. Atribuir amostras ao medóide mais próximo
3. Para cada medoid, calcule o custo total da distância.
4. Para cada medóide m e ponto p, calcule a redução na distância caso a troca fosse efetuada
5. Efetue a troca que trouxer o **maior ganho**
6. Repita os passos de 2 à 5 até convergência

[1] Kaufman, Leonard; Rousseeuw, Peter J. (1990). **Partitioning Around Medoids (Program PAM)**. Wiley Series in Probability and Statistics, Hoboken, NJ, USA: John Wiley & Sons, Inc., pp. 68–125, doi:10.1002/9780470316801.ch2, ISBN 978-0-470-31680-1

Complexidade de Tempo

- O laço de reatribuição de medóides do algoritmo original (PAM) possui complexidade $O(k(k-n)^2)$
- Armazenando as informações redundantes de maneira inteligente o algoritmo pode ser melhorado ainda mais[2]

[2]Erich Schubert, Peter J. Rousseeuw. **Fast and eager k-medoids clustering: O(k) runtime improvement of the PAM, CLARA, and CLARANS algorithms** (2021). Information Systems. Volume 101. https://doi.org/10.1016/j.is.2021.101804.

E se...

- Utilizar um passo iterativo similar ao k-means
- i.e. trocar o medoid pelo **ponto dentro do próprio grupo** que traga o melhor ganho (ao invés de comparar com toda a base de dados)
- Tem problemas de convergência pois raramente os medoides saem do próprio grupo. Isso reduz o espaço de busca, mas deixa o algoritmo muito sensível à inicialização

Vantagens e Desvantagens

- Pode ser aplicado com qualquer matriz de distâncias
- Elemento central faz parte do domínio de amostras
- Robusto à outliers
- Pode ser aplicado em grafos
- Mas é lento em comparação ao k-means

Discussão Distâncias

- Uma vez que podemos aplicar qualquer matriz de distância, podemos discutir algumas alternativas
  1. Shortest Path par-a-par
  2. Hamming na matriz de adjacências
  3. Produto Interno na matriz de adjacências
  4. Distâncias baseadas nos metadados

Discussão Hierarquias

- Podemos chamar um 2-medoids consecutivamente (o que tem um custo computacional mais elevado)
- Podemos usar as técnicas de remoção de arestas por betweeness para gerar hierarquias