Grafos e Redes Sociais

Passeio Aleatório e PageRank

Prof.

Fernando S. de Aguiar Neto

Sumário

1 Passeio Aleatório

2 Page Rank

Passeio Aleatório

1 Passeio Aleatório

2 Page Rank

Caminhando em um grafo

- Podemos considerar que vértices são ‘locais’ e arestas ligam esses locais
- Nesse contexto, podemos imaginar um transeunte que caminhe por esse grafo sem priorizar nenhum vértice
- Diremos que ele está efetuando um passeio aleatório no grafo

Motivação

- Podemos contabilizar a frequência com que alguns nós são visitados para uma determinada quantidade de passos nesse passeio
- Mais que isso, podemos notar que conforme o tamanho do passeio aumenta, alguns vértices tendem a ser mais ou menos visitados
- Iremos usar probabilidades, considerando que o transeunte comece em um vértice aleatório, qual a probabilidade de terminar seu passeio em determinado vértice?

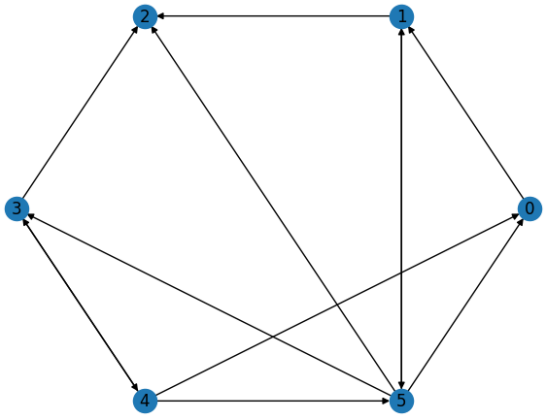
Motivação

- Essa informação pode identificar ralos (*sinks*) e fontes
- E também está diretamente relacionada à formação dos graus dos vértices, regiões muito conectadas tendem a 'prender' o viajante, pontes entre regiões conectadas tendem a ser visitadas várias vezes, etc.

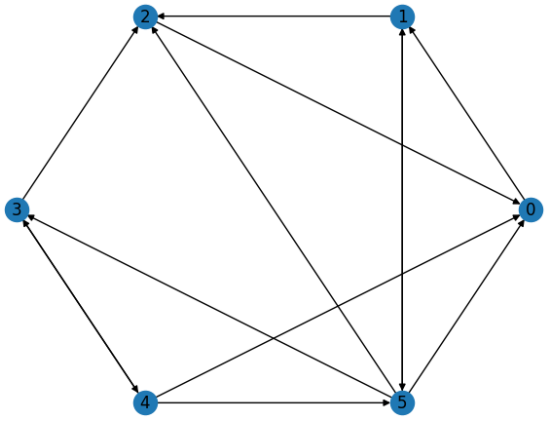
Simulando

- Podemos calcular essas probabilidades por meio de simulações, inicializandoo passeio em um vértice aleatório e caminhando aleatoriamente
- Uma média das contagens de visitas nas diferentes simulações irá aproximar muito bem a probabilidade real

Digrafo Exemplo 1



Digrafo Exemplo 2

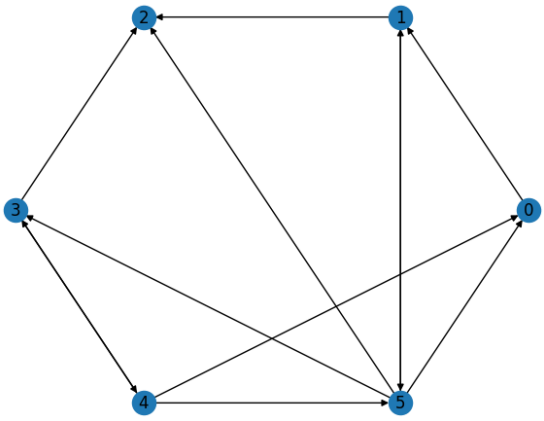


Calculando

- O processo de simulação é útil, mas é demorado
- Podemos usar a matriz de adjacências para calcular as probabilidades de terminar em cada vértice em um determinado número de passos

Matriz de Transições

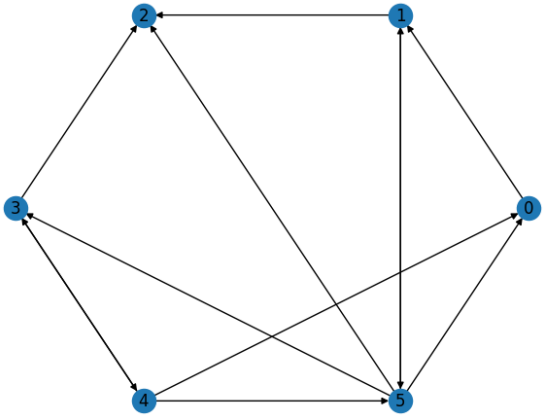
- Utilizaremos um recurso chamado de matriz de transições
- Essa matriz mapeia a probabilidade de mudança entre vértices



Matriz de Transições

0	1	0	0	0	0
0	0	1	0	0	1
0	0	0	0	0	0
0	0	1	0	1	0
1	0	0	1	0	1
1	1	1	1	0	0

Tabela 1: Matriz de Adjacências do grafo ao lado. Notem a assimetria, **linhas indicam a fonte e colunas o destino**



Matriz de Transições

- Notem que podemos adaptar essa matriz para medir as probabilidades de transição
- Basta dividir pelo grau de saída do vértice atual

0	$\frac{1}{1}$	0	0	0	0
0	0	$\frac{1}{2}$	0	0	$\frac{1}{2}$
0	0	0	0	0	0
0	0	$\frac{1}{2}$	0	$\frac{1}{2}$	0
$\frac{1}{3}$	0	0	$\frac{1}{3}$	0	$\frac{1}{3}$
$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	0	0

Tabela 2: Matriz de Transições do grafo. Notem que cada linha soma 1! I.e. 100%

Matriz de Transições

- Notem que podemos adaptar essa matriz para medir as probabilidades de transição
- Basta dividir pelo grau de saída do vértice atual
- Por exemplo, saindo do vértice 1 temos 50% de chances de ir para o vértice 2 ou para o vértice 5

0	$\frac{1}{1}$	0	0	0	0
0	0	$\frac{1}{2}$	0	0	$\frac{1}{2}$
0	0	0	0	0	0
0	0	$\frac{1}{2}$	0	$\frac{1}{2}$	0
$\frac{1}{3}$	0	0	$\frac{1}{3}$	0	$\frac{1}{3}$
$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	0	0

Tabela 3: Matriz de Transições do grafo.

Matriz de Transições

- Agora vamos fazer iterações repetidas e ver como esse processo funciona com **2 passos** (exercício/lousa)

0	$\frac{1}{1}$	0	0	0	0
0	0	$\frac{1}{2}$	0	0	$\frac{1}{2}$
0	0	0	0	0	0
0	0	$\frac{1}{2}$	0	$\frac{1}{2}$	0
$\frac{1}{3}$	0	0	$\frac{1}{3}$	0	$\frac{1}{3}$
$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	0	0

Tabela 4: Matriz de Transições do grafo.

Generalizando

- Fizemos o processo escolhendo as linhas convenientes em cada etapa
- mais que isso, precisamos manter as probabilidades de vários caminhos distintos
- Podemos efetuar essas operações simultaneamente usando vetores!

Escolhendo vértice inicial

- Vamos colocar 1 na posição do vértice inicial desejado e 0 nas demais posições
- e.g. para o vértice 1, temos o vetor: $[0\ 1\ 0\ 0\ 0\ 0]$
- O que acontece ao multiplicar esse vetor pela matriz de transições?

$$[0\ 1\ 0\ 0\ 0\ 0] * \begin{bmatrix} 0 & \frac{1}{1} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{3} & 0 & 0 & \frac{1}{3} & 0 & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{bmatrix}$$

Escolhendo vértice inicial

$$[0\ 1\ 0\ 0\ 0\ 0] * \begin{bmatrix} 0 & \frac{1}{1} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{3} & 0 & 0 & \frac{1}{3} & 0 & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \end{bmatrix}$$

Escolhendo vértice inicial

- Temos 50% de chances de estar em 2 e 50% de chances de estar em 5!
- Notem que o nosso vetor inicial, tinha 100% de chances de estar em 1

$$\begin{bmatrix} 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \end{bmatrix}$$

Escolhendo vértice inicial, segundo passo

- Temos 50% de chances de estar em 2 e 50% de chances de estar em 5!
- Notem que o nosso vetor inicial, tinha 100% de chances de estar em 1
- Podemos repetir o processo para encontrar as probabilidades em **2 passos**!

$$\begin{bmatrix} 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \end{bmatrix} * \begin{bmatrix} 0 & \frac{1}{1} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{3} & 0 & 0 & \frac{1}{3} & 0 & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{bmatrix}$$

Escolhendo vértice inicial, segundo passo

$$\begin{bmatrix} 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \end{bmatrix} * \begin{bmatrix} 0 & \frac{1}{1} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{3} & 0 & 0 & \frac{1}{3} & 0 & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0 & 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{8} & \frac{1}{8} & \frac{1}{8} & \frac{1}{8} & 0 & 0 \end{bmatrix}$$

Escolhendo vértice inicial, segundo passo

- Começando no vértice 1 e andando exatamente 2 passos, temos 1/8 de chances de estar em 4 vértices diferentes...
- é razoável, mas notem que isso nõ soma 100%
- isso aconteceu pois o vértice 2 é um *sink*, não possui saída para lugar algum e encerraria o passeio ao ser alcançado!

$$\left[\frac{1}{8}\ \frac{1}{8}\ \frac{1}{8}\ \frac{1}{8}\ 0\ 0\right]$$

Adaptando a matriz de transições

- Para corrigir esse problema, adicionaremos auto-arestas (loops)
- Desse modo, um vértice sem saída irá sempre apontar para si mesmo como próximo vértice
- Podemos preenher toda a diagnoal principal da matriz de adjacencia com 1's, OU colocar auto-arestas apenas nos vértices com grau de saída igual a 0
- Essa decisão irá impactar a maneira como o caminhante explora o grafo

Exercícios

- O grafo do slide 9 não possui nenhum vértice com grau de saída igual a 0. Aplique o algoritmo como vimos para verificar as probabilidades após 1,2, ou 3 passos partindo do vértice 1
- Implementem em python um algoritmo para fazer o passeio aleatório dada uma quantidade de passos[1]

[1] dica, usem a biblioteca numpy e o comando np.dot()

Saindo de um vértice aleatório

- Inicializamos o procedimento com um vetor especial indicando que temos 100% de chances de começar no vértice 1
- $[0\ 1\ 0\ 0\ 0\ 0]$
- Para generalizar diremos que temos uma chance igual de estar em qualquer vértice
- $\left[\frac{1}{6}\ \frac{1}{6}\ \frac{1}{6}\ \frac{1}{6}\ \frac{1}{6}\ \frac{1}{6}\right]$

Detalhes

- fontes e ralos são problemáticos e exigirão uma tomada de decisão
- e.g. podemos dizer que o caminhante sempre parte de uma fonte ao invés de um vértice qualquer
- quanto aos ralos podemos decidir que o caminhante fica preso, ou que pode ir para qualquer lugar aleatoriamente, ou que o passeio termina e deve ser reiniciado

Page Rank

1 Passeio Aleatório

2 Page Rank

Page Rank

- Um algoritmo que usa o conceito de passeio aleatorio é o PageRank
- O conceito geral é: “Uma pessoa clicando a esmo em links na internet deve visitar mais vezes páginas importantes e bem conectadas em comparação à páginas pouco importantes”
- É uma medida de centralidade, a importância se dá pela chance de visitar uma pagina aleatoriamente

Similar ao que já vimos

- O PageRank de um vertice é calculado como a probabilidade de estar em um vértice após vários passos
- Além disso, considera a possibilidade ocasional do visitante parar de seguir os links das páginas e acessar uma página aleatória
- Efetivamente, 'teletransportando'

Equação do PageRank[2]

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- Sendo p' o vetor de probabilidades de visita aos vértices após uma iteração
- p é o vetor de probabilidade da iteração anterior
- B é a matriz de transições (sem alterações)
- 1^T é um vetor de 1's transposto (i.e. 'vetor linha')
- c é a probabilidade do viajante se manter na trajetória
- n é a quantidade de vértices

[2] A formulação original inverte algumas multiplicações, usando a transposta da matriz de transições, para fins de consistência com o resto da aula, adaptei a fórmula

Equação do PageRank - Digerindo

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- Vamos aos poucos
- O início da fórmula é similar ao que já vimos anteriormente

Equação do PageRank - Digerindo

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- $c \in (0, 1]$ é a probabilidade de o caminhante seguir o trajeto normal
- (1-c) é a probabilidade de ele 'teletransportar' para algum vértice qualquer (inclusive o próprio)
- O vetor 1^T ao ser dividido por n acaba se tornando um vetor de $\frac{1}{n}$, com as mesmas dimensões de p, expressando a possibilidade uniforme de visitar outros vértices

Equação do PageRank - Digerindo

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- c e (1-c) ponderam as probabilidades de seguir o caminho ou teletransportar, como se adicionássemos conexões extras de um vértice para todos os outros com uma probabilidade menor
- Notem que caso c=1, temos o caso do passeio aleatório normal

Equação do PageRank - Funcionamento

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- Se iterarmos algumas poucas vezes (e.g. 10 a 30) veremos que os valores irão convergir
- Isso é garantido por algumas propriedades da matriz B, especialmente o fato de não existirem sinks e que todos os nós são alcançáveis a todo momento
- Na primeira iteração p pode ser inicializado como um vetor de (1/n)'s como vimos no nosso exemplo de random walk

Equação do PageRank - Personalizando

$$p' = c * p\mathbf{B} + \frac{(1-c)}{n} * \mathbf{1}^T$$

- Para utilizar as preferências pessoais e personalizar esse rank é possível alterar o vetor de 'teletransporte'
- Ao invés de usar 1 para todos os vértices, usar 1 apenas nos vértices com alta chance de acesso, ou seja ele não irá acessar qualquer outra página, irá acessar alguma de um subconjunto que ele prefere
- Isso pode ser ainda mais refinado dando pesos distintos para páginas diferentes, detalhando ainda mais as probabilidades de mudança

Exercícios

- Executem algumas iterações do pagerank para as matrizes que vimos anteriormente
- Em python a biblioteca networkX calcula o pagerank, vejam o comportamento dele em grafos diferentes
- Implementem o pagerank sem personalização