# Grafos e Redes Sociais

Detecção de Comunidades

Prof.

**Fernando S. de Aguiar Neto**

# Sumário

1 Motivação

2 Avaliando Comunidades

3 Otimizando Modularidade

# Motivação

1 Motivação

2 Avaliando Comunidades

3 Otimizando Modularidade

# Segmentando Grafos

- Temos o interesse em segmentar regiões similares em grafos, por exemplo:
  - **Redes Sociais e Marketing:** encontrar grupos de pessoas com gostos similares
  - **Setor médico:** interação de proteínas, redes neurológicas, etc.
  - **Organização de conteúdos:** filtrar e segmentar páginas web
  - **Logística:** regiões com demandas similares

## Segmentando Grafos

- Segmentar também traz vantagens na análise de grafos
- Muitos grafos possuem uma grande divergência em suas métricas dependendo da "região" estudada. Ou seja, há grandes **diferenças locais**
- Segmentar o grafo em sub-regiões permite uma análise local, com vértices similares entre si

## Grupos em Grafos

- Detectar similaridades em um grafo é uma tarefa delicada
- Intuitivamente podemos pensar que elementos similares estão próximos em um grafo poderado
- mas em um grafo não-ponderado só podemos pensar em inter-conexões entre vértices
- De modo geral, temos uma visão similar à de agrupamento de dados clássica: "Queremos deixar vértices **similares** em uma **mesma comunidade** (grupo) e vértices dissimilares em comunidades (grupos) distintas"

## Grupos em Grafos

- "Queremos deixar vértices **similares** em uma **mesma comunidade** (grupo) e vértices dissimilares em comunidades (grupos) distintas"
- Como podemos estabelecer essas similaridades?
- Em um espaço euclidiano podemos usar métricas de distância, mas em um grafo ferimos várias premissas necessárias para medir distâncias
- Especialmente em grafos poderados e direcionados
- Como calcular similaridades entre vértices em grafos não ponderados?
- É necessário calcular distâncias par-a-par?

# Avaliando Comunidades

1 Motivação

2 Avaliando Comunidades

3 Otimizando Modularidade

## Em espaços métricos

- Se uma medida de distância é bem definida entre pares de vértices (adjacências)
- Podemos usar ferramentas da álgebra e traçar medóides e estimar a soma das variâncias, silhueta, etc.

## Com Padrão-Ouro

Caso um padrão-ouro esteja estabelecido, podemos usar avaliação externa de agrupamento, por exemplo:

- Jaccard Index
- Informação Mútua
- Matriz de confusão par-a-par

# Modularidade[1]

- Compara a presença de arestas intra-comunidades com o acaso
- O modelo ao acaso deve preservar não só as quantidades de vértices e arestas como também a **distribuição de graus do grafo**

[1] Newman, M. E. J. (2006). **"Modularity and community structure in networks"**. Proceedings of the National Academy of Sciences of the United States of America. 103 (23): 8577–8696. Disponível publicamente em: `https://arxiv.org/abs/physics/0602124`

# Modularidade - Modelo Nulo

- O modelo nulo para comparação usando modularidade é realizado da seguite maneira:
  1. 'Cortar' todas as arestas ao meio, chamaremos cada 'meia-aresta' de *stub*
  2. Reconectar aleatoriamente stubs com outros stubs até que não hajam stubs, apenas arestas

## Modularidade - Modelo Nulo

- Esse algoritmo garante a mesma distribuição de graus do grafo original
- Contudo, assume a possibilidade de arestas múltiplas e auto-arestas
- Isso pode trazer problemas de resolução no cálculo da modularidade como será discutido mais adiante

# Modularidade - Expectativas no Modelo Nulo

- Podemos calcular valores esperados para o modelo nulo, permitindo efetuar um cálculo geral para a modularidade, sem a necessidade de reconectar as arestas do grafo
- Considerando um stub qualquer ($I_i(v, w)$) de um nó $v$, temos uma probabilidade que ele se conecte a qualquer outro stub, a probabilidade desse stub pertencer à um vértice w depende do grau de w (i.e. $k_w$)

$$P(\mathbf{I_i}(v, w) = 1) = \frac{k_w}{2m - 1} \tag{1}$$

# Modularidade - Expectativas no Modelo Nulo

$$P(\mathbf{I_i}(v,w)) = \frac{k_w}{2m-1} \tag{2}$$

- Como cada stub de v terá a mesma probabilidade de conexão com outros stubs e temos $k_v$ conexões saindo de v a probabilidade de conexão entre dois vértices v e w é dada por:

$$P(\textbf{Ligação}(v,w)) = \frac{k_v k_w}{2m-1} \tag{3}$$

# Modularidade - Expectativas no Modelo Nulo

- Para grandes quantidade de arestas o cálculo pode ser simplificado para

$$P(\textbf{Ligação}(v, w)) = \frac{k_v k_w}{2m} \tag{4}$$

- Além disso, a probabilidade de multi-arestas e auto-arestas tende a ficar negligível conforme a quantidade de vértices aumenta, logo não precisamos ajustar isso

# Modularidade - Diferença entre Comunidade e Nulo

$$A_{vw} - \frac{k_v k_w}{2m} \tag{5}$$

Sendo $A_{vw}$ a matriz de adjacências. Temos a diferença entre o grafo estudado e o modelo nulo. Repetindo o processo para todos os pares de vértices temos a modularidade completa

## Modularidade

$$Q = \frac{1}{2m} \sum_{(v,w) \in G} \left( A_{vw} - \frac{k_v k_w}{2m} \right) \delta(v, w) \tag{6}$$

- Sendo $\delta(v, w)$=1 caso v e w pertençam à mesma comunidade, 0 caso contrário.
- podemos simplificar essa fórmula

# Modularidade - Não-direcionado

$$Q = \sum_{i=1}^{c} \left[ \frac{L_i}{m} - \left( \frac{k_i}{2m} \right)^2 \right] \tag{7}$$

- É possível mostrar que essa fórmula é equivalente à anterior
- Sendo $L_i$ a quantidade de vértices na comunidade $i$
- $k_i$ a soma dos graus dos vértices da comunidade i

# Modularidade - Direcionado

$$Q = \sum_{i=1}^{c} \left[ \frac{L_i}{m} - \left( \frac{k_i^{in} k_i^{out}}{2m} \right)^2 \right] \tag{8}$$

- É possível mostrar que essa fórmula é equivalente à anterior
- Sendo $L_i$ a quantidade de vértices na comunidade $i$
- $k_i^{in}$ $k_i^{out}$ a soma dos graus de entrada e saída dos vértices da comunidade i

# Modularidade - Extremos

$$Q = \sum_{i=1}^{c} \left[ \frac{L_i}{m} - \left( \frac{k_i}{2m} \right)^2 \right] \tag{9}$$

- Para um grafo não-direcionado e sem pesos, $Q \in [-0.5, 1]$ e é positivo quando a quantidade de arestas intra-comunidade excede a quantidade esperada de conexões

# Modularidade - Resolução

- O modelo nulo da modularidade assume que qualquer vértice pode se conectar com qualquer um dos outros
- Isso não é verdade para redes reais, especialmente as grandes
- Uma maneira de adaptar a modularidade é adicionar um fator de regularização $\gamma$ para atenuar ou incentivar o impacto do modelo nulo

$$Q = \sum_{i=1}^{c} \left[ \frac{L_i}{m} - \gamma \left( \frac{k_i}{2m} \right)^2 \right] \tag{10}$$

# Otimizando Modularidade

1 Motivação

2 Avaliando Comunidades

3 Otimizando Modularidade

# Otimizando

- Se a modularidade é uma medida boa para avaliar comunidades
- Podemos escolher as comunidades de modo à maximizar a modularidade
- É uma abordagem adequada, mas que pode trazer resultados indesejados, uma vez que redes aleatórias ou livres de escala ainda podem produzir redes com modularidade alta[2]

[2] Guimera, R.; Sales-Pardo, M. (2004). **"Modularity from fluctuations in random graphs and complex networks"**, Physical Review, 70 (2): 025101. Disponível publicamente em `https://arxiv.org/abs/cond-mat/0403660`

## Algoritmo Guloso

Podemos encontrar comunidades com um algoritmo guloso por subida de encosta:

1. Inicializar cada vértice em uma comunidade distinta
2. Unir duas comunidades de modo a maximizar o aumento da modularidade
3. Repetir passo 2 até enquanto for possível aumentar a modularidade